
사물인터넷

연합 학습 기반 IoT 이상 탐지 논문 발표

팀원
권우현 박준성 김준서

발표자
권우현

발표일시
2025년 12월 5일

목차

01. 연구 배경 및 필요성

02. 문제 정의 및 기존 한계


03. 제안 방법
(FedDetect + FL 개념)

04. 데이터셋 및 시스템 구성

05. 실험 결과 및 실제 구현 결과


06. 결론 및 향후 연구

팀원 소개




권우현

- 팀장 및 발표자
- 실험
- FedDetect 알고리즘 구현
- 결과 시각화



박준성

- 실험
- 데이터 전처리
- PPT 제작



김준서

- 실험
- 데이터셋 분석
- PPT 제작

연구 배경 및 필요성

논문 선정 이유

논문 선정 제목:

Federated Learning fore Internet of Things:

A Federated Learning Framework for On-Device Anomaly Data Detetion (ACM SenSys 2021)

➤ 번역: IoT를 위한 연합 학습: 온-디바이스 이상 데이터 탐지를 위한 연합 학습 프레임워크

선정 이유

- 단순 FL 알고리즘이 아닌, IoT 기기 환경에서 발생하는 '이상 탐지'라는 핵심 문제가 주제에 적합하다고 판단
- Federated learning에 대한 기초적인 지식에 대한 기반을 함께 학습할 수 있음
- FedDetect라는 개념을 도입하여 기존의 이상 탐지에 한층 더 고수준의 알고리즘을 구현하고, 플랫폼 구축을 목적으로 하여 논문의 실용성 및 목적성이 뛰어남

FEDERATED LEARNING FOR INTERNET OF THINGS:
A FEDERATED LEARNING FRAMEWORK FOR ON-DEVICE
ANOMALY DATA DETECTION

A PREPRINT

Tuo Zhang*, Chaoyang He*, Tianhao Ma, Lei Gao, Mark Ma, Salman Avestimehr
Viterbi School of Engineering
University of Southern California
{tuozhang, chaoyang.he, tianhaom, leig, mzma, avestime}@usc.edu

October 19, 2021

ABSTRACT

Federated learning can be a promising solution for enabling IoT cybersecurity (i.e., anomaly detection in the IoT environment) while preserving data privacy and mitigating the high communication/storage overhead (e.g., high-frequency data from time-series sensors) of centralized over-the-cloud approaches. In this paper, to further push forward this direction with a comprehensive study in both algorithm and system design, we build FedIoT platform that contains FedDetect algorithm for on-device anomaly data detection and a system design for realistic evaluation of federated learning on IoT devices. Furthermore, the proposed FedDetect learning framework improves the performance by utilizing a local adaptive optimizer (e.g., Adam) and a cross-round learning rate scheduler. In a network of realistic IoT devices (Raspberry PI), we evaluate FedIoT platform and FedDetect algorithm in both model and system performance. Our results demonstrate the efficacy of federated learning in detecting a wider range of attack types occurred at multiple devices. The system efficiency analysis indicates that both end-to-end training time and memory cost are affordable and promising for resource-constrained IoT devices. The source code is publicly available at

수행 계획

1) 논문 심층 분석 및 환경 구축

- 논문의 전반적인 내용을 깊이 있게 이해하고, 충분히 설명할 수 있을 정도의 지식 습득
- 논문에서 제시한 FedIoT 아키텍처 및 Deep Autoencoder 모델 구조 파악
- FL 시뮬레이션 환경(FedML/Python) 구축 및 Github 코드 분석

2) 데이터 분할 및 로컬 구현

- IoT 이상 탐지 데이터셋(추가 데이터셋)을 클라이언트별로 분할
- Autoencoder 모델을 구성하고, 각 클라이언트에서 로컬 학습 기능 구현

3) FedIoT 알고리즘 재구현 및 검증

- FedAvg를 기반으로 이상 탐지 모델 업데이트 및 중앙 서버 집계 로직 구현
- 논문에서 제시된 지표를 사용해 성능 평가(Accuracy, Recall)

4) 최종 정리 및 발표 준비

- 구현 결과 정리 및 시각화
- 논문 분석 내용, 구현 과정의 난점 및 해결책을 중심으로 발표 자료 준비

연구 배경: IoT 보안의 중요성



- 전 세계 수십억 **IoT** 기기의 확산으로 인해 공격 표면이 기하급수적으로 확대
- IoT 장치가 수집하는 개인정보 및 운영 데이터의 민감도 상승으로 인한 보안 위험 증가
- 에지에서 발생하는 고빈도/대용량 네트워크 트래픽으로 인한 효율적인 이상 탐지의 어려움
- 중앙 서버 의존 시 프라이버시, 비용, 지연 문제 심화
- **Mirai, BASHLITE** 등 IoT 타깃 봇넷 공격 증가로 분산 방어 체계 필요성 대두

문제 정의 및 기존의 한계

문제 정의 및 기존 연구 한계

클라우드 중심 접근법의 한계

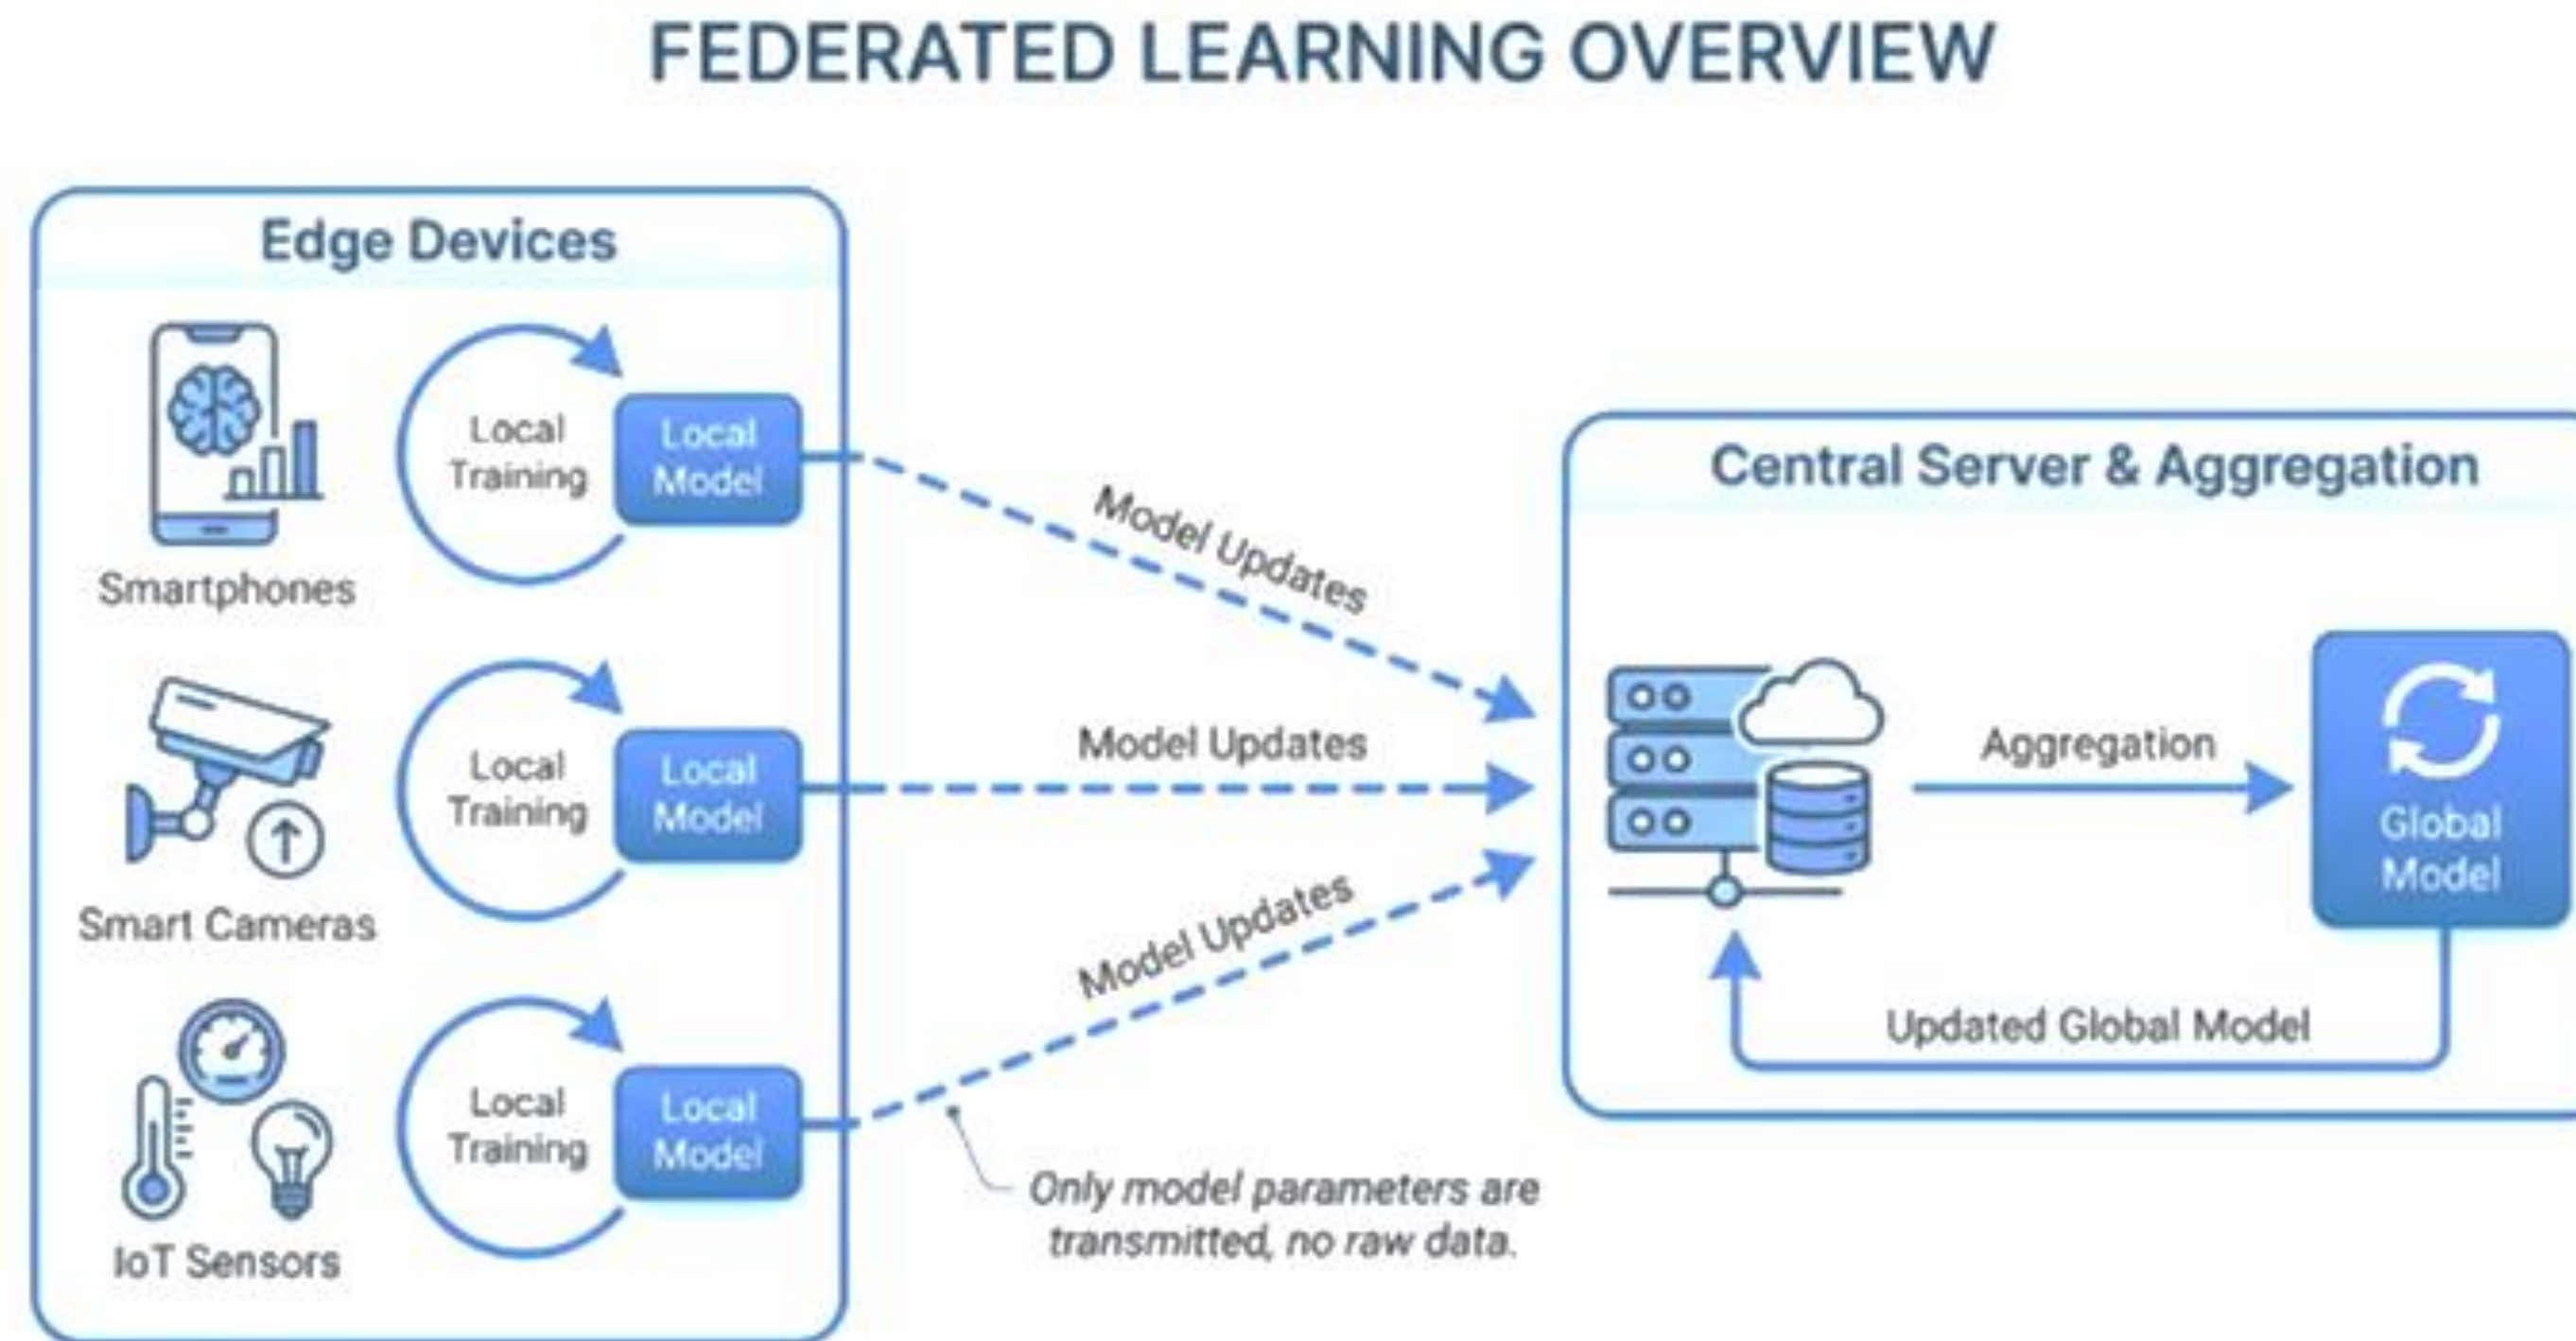
- ❑ 데이터 수집·전송 오버헤드
 - 고빈도 IoT 데이터의 중앙 서버 전송 시 대역폭/지연 문제
- ❑ 개인정보 민감성
 - 민감한 IoT 데이터의 중앙화로 인한 개인정보 및 규제 리스크 증가
- ❑ Non-IID/불균형 데이터
 - 장치별 다양한 데이터 특성에 중앙 모델 대응 어려움
- ❑ 단일 장애점(Single Point Of Failure)
 - 중앙 서버 장애 시 전체 시스템 취약

필요한 접근 방식 요구사항

- ❑ 온-디바이스 학습과 프라이버시
 - 민감 데이터를 로컬에 유지하며 학습
- ❑ 통신량 절감 및 장치 확장
 - 모델 파라미터만 교환, 다수 장치 확장 가능
- ❑ 다양한 장치 지원
 - 다양한 리소스와 데이터 특성을 가진 장치들의 협업 가능
- ❑ 개인 및 글로벌 조화
 - 장치별 특성 유지하며 전체 모델 개선

제안 방법

연합 학습(Federated Learning) 개념



① 장치 로컬에서 모델 학습
데이터는 장치에 유지

② 모델 파라미터만 서버로 전송
프라이버시 보호

③ 서버는 파라미터 집계
글로벌 모델 생성

④ 통신 라운드 반복, 협업 학습 실현

관련 연구

01. FL 기초 알고리즘

- FedAvg: 기본 FL 알고리즘, 클라이언트 모델 가중치 평균화
- FedProx: 이질성 해결, 근접 항 추가해 로컬 최적화 제약
- SCAFFOLD: 클라이언트 드리프트 수정 통해 수렴 가속
- FedOpt/FedAdam: 적응형 옵티마이저 도입한 서버 측 집계

02. IoT 침입 탐지 연구

- Autoencoder 기반 이상 탐지: 재구성 오류 기반 비지도 탐지
- N-BalIoT 활용 연구: 실제 IoT 기기 공격 데이터로 검증

03. 최신 동향


- 블록체인 결합: 검증 및 투명성 향상 위한 통합 연구
- 개인화 FL: 특정 클라이언트 맞춤형 모델 최적화 연구
- 통신 효율화: 압축, 양자화, 희소 업데이트 연구
- 비동기 FL: 클라이언트 동기화 없이 학습 최적화

FedDetect 프레임워크 개요

FedDetect 프레임워크 구조

IoT 장치 (로컬)

- Autoencoder 모델
- 로컬 학습 (Adam)
- 정상 데이터 학습
- MSE 기반 이상 탐지



중앙 서버

- 모델 파라미터 집계
- 적용형 옵티마이저
- 라운드별 학습률 조정
- 글로벌 임계값 계산

- 1 목적: 온-디바이스 이상 데이터 탐지 성능 극대화
- 2 핵심 구성: Autoencoder 기반 로컬 학습 + 서버 적용형 집계
- 3 차별점: Adam 옵티마이저 + 라운드 간 학습률 스케줄러
- 4 Global Threshold 모듈: 장치별 통합 임계값 산출

FedDetect 핵심 알고리즘

01. 초기화: 글로벌 AE 파라미터

- 서버에서 초기 **Autoencoder** 모델 파라미터를 생성하여 모든 참여 IoT 장치에 배포
- 입력 115차원, 4개 은닉층 구성(75%, 50%, 33%, 25%)

02. 로컬 학습: Adam 옵티마이저

- 각 IoT 장치에서 **Adam** 옵티마이저를 사용하여 로컬 데이터로 학습
- 배치 크기 64, T 라운드 반복 수행하며 MSE 손실함수 최소화

03. 서버 집계: 적응형 옵티마이저

- 서버는 **FedAdam** 계열의 적응형 옵티마이저로 장치별 모델을 집계
- 기존 FedAvg와 달리 모멘텀과 적응적 학습률 활용으로 수렴 속도 개선

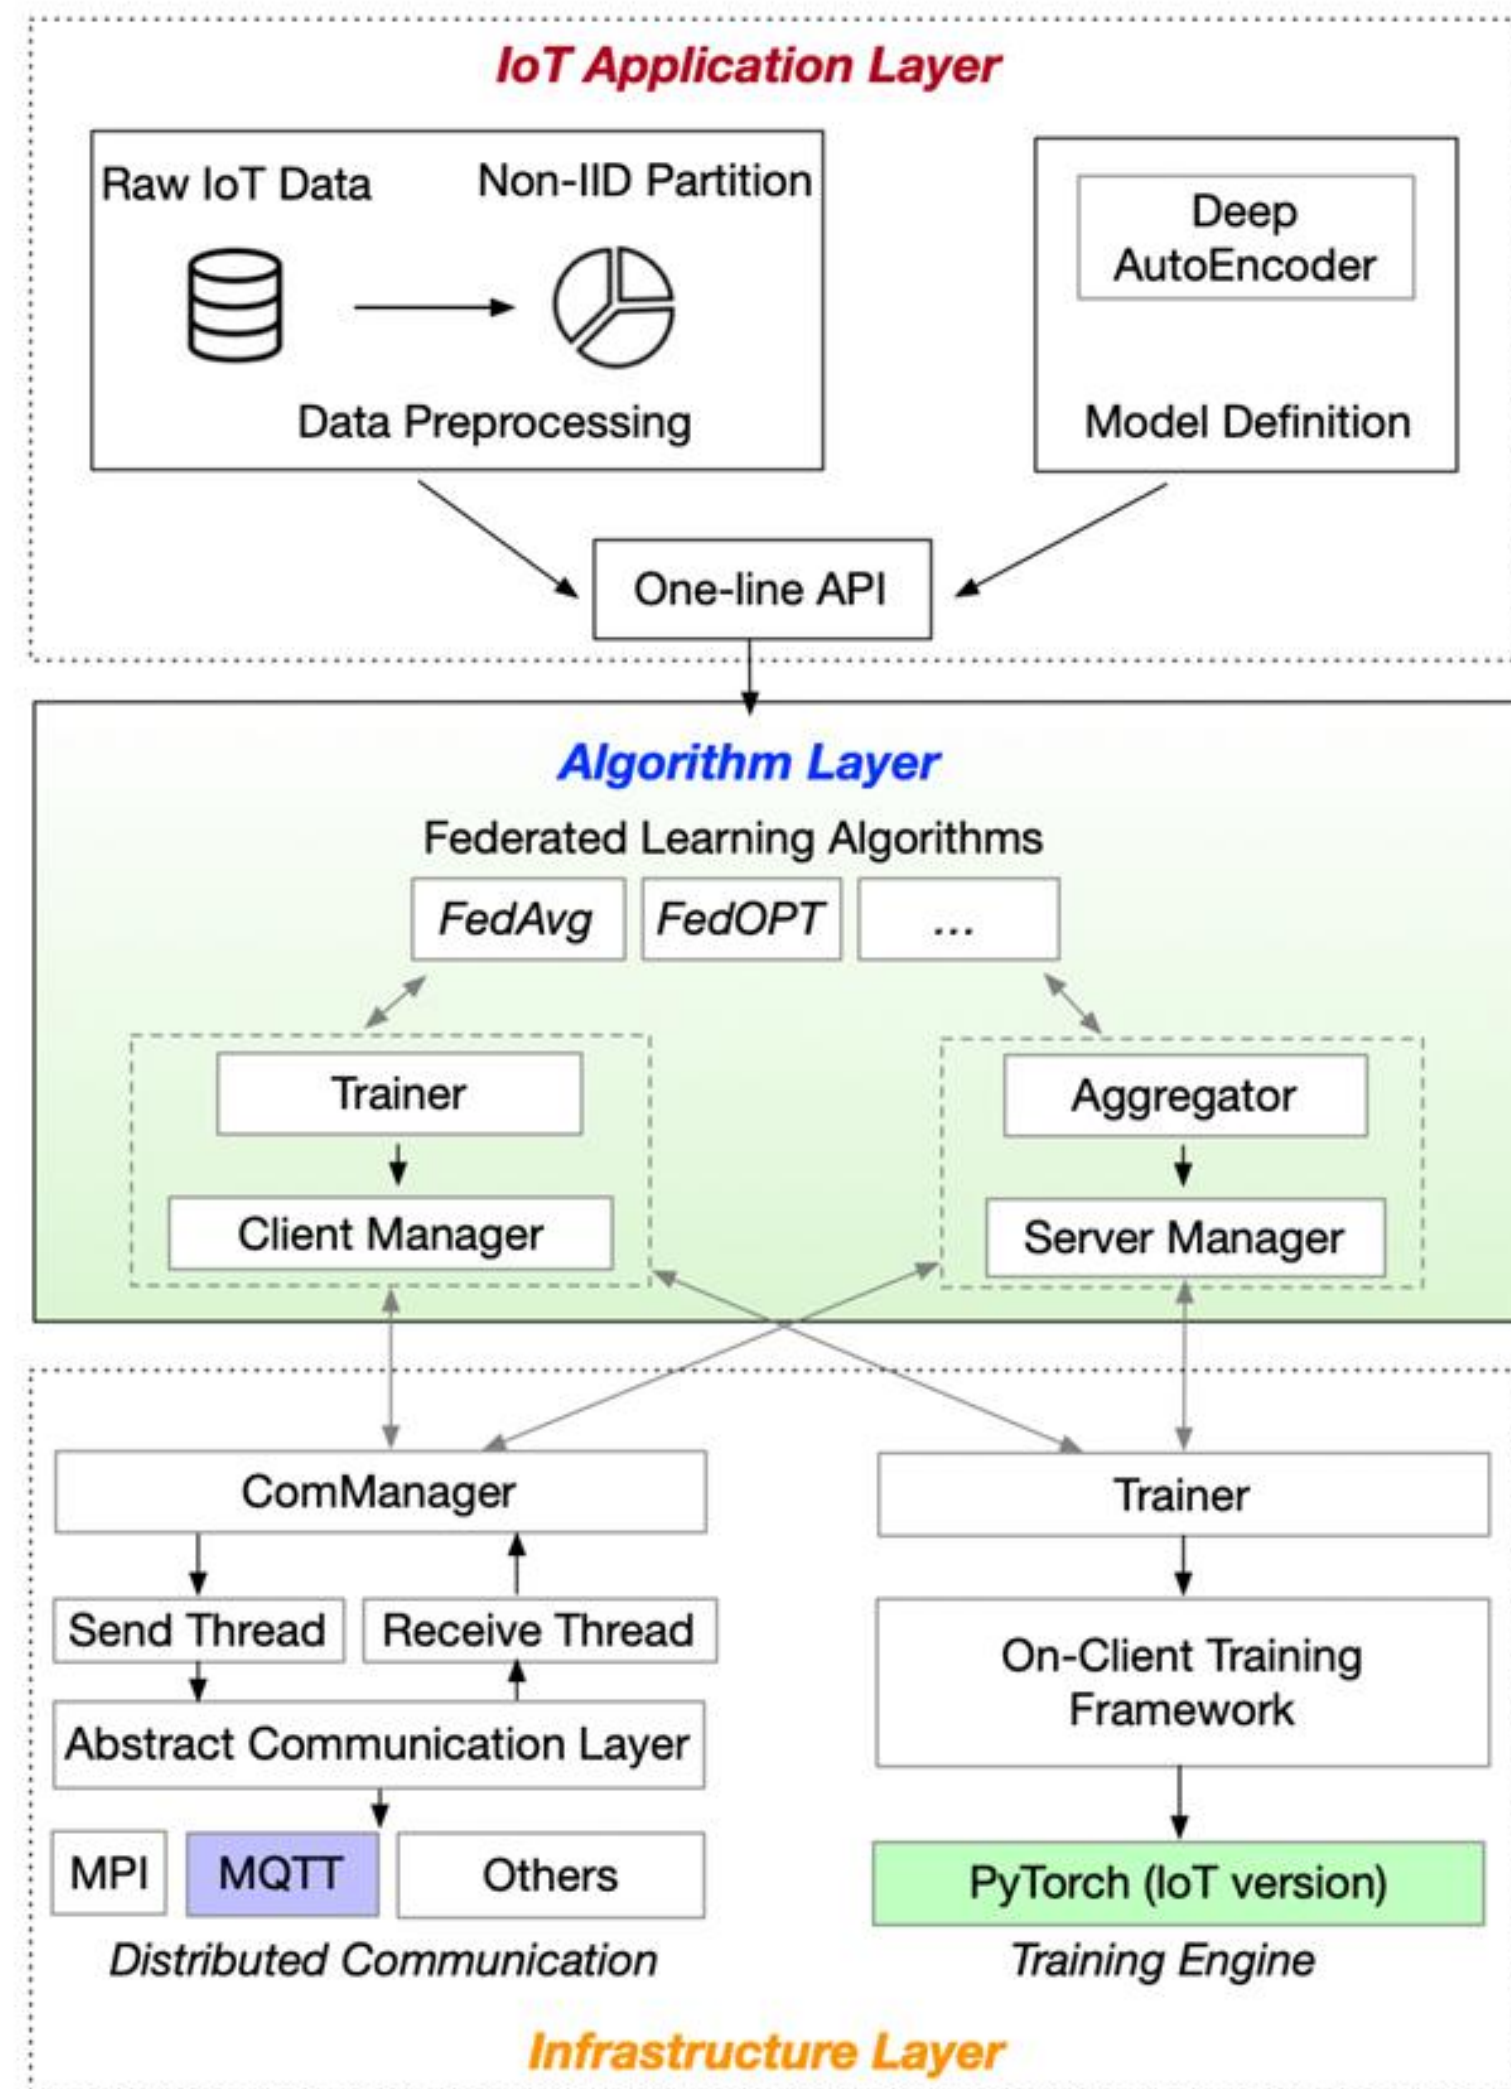
04. 학습률 스케줄링

- **라운드 간 학습률 동적 조정**으로 초기에는 빠른 학습, 후기에는 미세 조정이 가능하도록 설계
- 비선형 감쇠 또는 코사인 스케줄링 적용

05. 글로벌 임계값 산출

- 각 장치에서 정상 데이터로 **MSE 시퀀스**를 생성하고 서버에서 통합하여 장치별 최적화된 이상 탐지 임계값을 결정
- 이상 탐지 정확도 향상의 핵심 차별점

FedIoT 플랫폼 : 3계층 아키텍처



Application Layer

사용자 인터페이스와 API 제공

- 한 줄 API로 Autoencoder와 데이터 로더 등록
- 간편한 FL 설정 및 모델 훈련 시작 기능
- 데이터 전처리 및 결과 시각화 도구 제공

Algorithm Layer

FL 알고리즘과 학습 프로세스 관리

- FedDetect, FedAvg, FedOpt 등 다양한 알고리즘 지원
- 사용자 정의 트레이너와 집계 함수 확장 가능
- 클라이언트/서버 매니저로 인스턴스 관리

Infrastructure Layer

통신 및 하드웨어 인프라 관리

- MQTT/MPI 통신 백엔드로 효율적 메시징
- Raspberry Pi, Jetson Nano 등 엣지 장치 지원
- 맞춤형 PyTorch 라이브러리 기반 실장치 학습

데이터 및 시스템 구성

실험 설계: 데이터셋·모델·환경

01. N-BaIoT 데이터셋

- 데이터 구성: 9개 상용 IoT 장치의 네트워크 트래픽
- 공격 유형: Mirai 및 BASHLITE 계열 악성코드 공격
- 데이터 분할: 정상 5000(학습)/3000(평가), 균형 테스트셋 생성
- 테스트셋 합성: 각 공격유형 500개 + 정상 500개로 균형화

02. 모델 구조

- 입력 차원: 115D 네트워크 트래픽 특성 벡터
- Autoencoder: 인코더 4층 (75%-50%-33%-25%), tanh 활성화
- 하이퍼파라미터: batch size 64, epoch 120, Rounds 30
- 로컬 옵티마이저: Adam, 서버 집계: FedAdam

03. 실험 환경

- 하드웨어: 9×Raspberry Pi 4B (클라이언트) + GPU 서버
- 통신: MQTT 프로토콜, 무선 환경
- 비교 기준: CL-Single vs. CL-Combined vs. FL-FedDetect
- 평가 지표: ACC (Accuracy), TPR (True Positive Rate), FPR (False Positive Rate), TNR(True Negative Rate)

실험 결과 및 실제 구현 결과

실험 결과(1): 탐지 성능 비교




Table 1: Performance of anomaly detection under both centralized training and federated training

	Acc	FPR	TPR	TNR
CL-Single	73.82%	37.50%	86.56%	62.50%
CL-Combined	98.64%	2.71%	99.99%	97.29%
FL-FedDect	98.27%	3.45%	99.99%	96.55%

Table 2: CPU/GPU Training v.s. IoT Edge Training

	Acc	FPR	TPR	TNR
Simulation	98.27%	3.45%	99.99%	96.55%
Raspberry Pi	97.47%	4.78%	99.99%	95.22%

비교 결과 요약

- FedDetect는 중앙집중식 학습(CL-Combined) 상황에 근접한 우수한 성능을 보이며, 개별 장치 학습(CL-Single) 대비 우수한 이상 탐지 정확도 달성
- 특히 IoT 디바이스 간 데이터 협업을 통해 TPR(True Positive Rate)이 크게 향상되었으며, FPR(False Positive Rate)은 적절히 유지

성능 지표 설명

- Accuracy: 전체 탐지 정확도
- TPR: 공격 탐지 성공률(재현율)
- FPR: 오탐률(위양성율)
- TNR: 정상 트래픽 정확도(특이도)

실험 결과(2): 효율성 분석

시스템 효율성 요약

- FedDetect는 Raspberry Pi 4B와 같은 제한된 리소스 환경에서도 효율적으로 작동 가능
- 라운드당 학습 시간은 1분 미만으로, 실용적인 온-디바이스 학습이 가능
- 메모리 사용량은 제한된 장치에서도 부담이 없으며, 7.65MB/s의 일반적인 무선 환경에서도 원활한 연합 학습을 수행할 수 있음

통신 효율성

- FedIoT 플랫폼은 MQTT 기반 경량 메시징을 사용하여 통신 오버헤드를 최소화합니다. 모델 파라미터만 전송하므로 중앙 집중식 방식 대비 데이터 전송량이 크게 감소
- FedDetect의 효율성은 다양한 IoT 환경에서 실시간 이상 탐지를 위한 실제 배포 가능성을 보여줌


리소스 제약 환경에서의 효율성 지표



Used Memory: 46.5MB


Total Memory: 4GB

(a) Memory Percentage



(b) Running Time Per Round

실제 재현 결과(1): Threshold



Global Threshold

- FedIoT는 각 클라이언트들의 개별 학습 후, Threshold를 중앙으로 보내 FedAvg를 통하여 Global Threshold를 정의
- Threshold 값은 약 0.0324로 수렴하였고, 이는 정상데이터만을 학습했기 때문에 생긴 값
- 차후 Threshold는 공격 탐지에 대한 이진 분류에서 사용됨

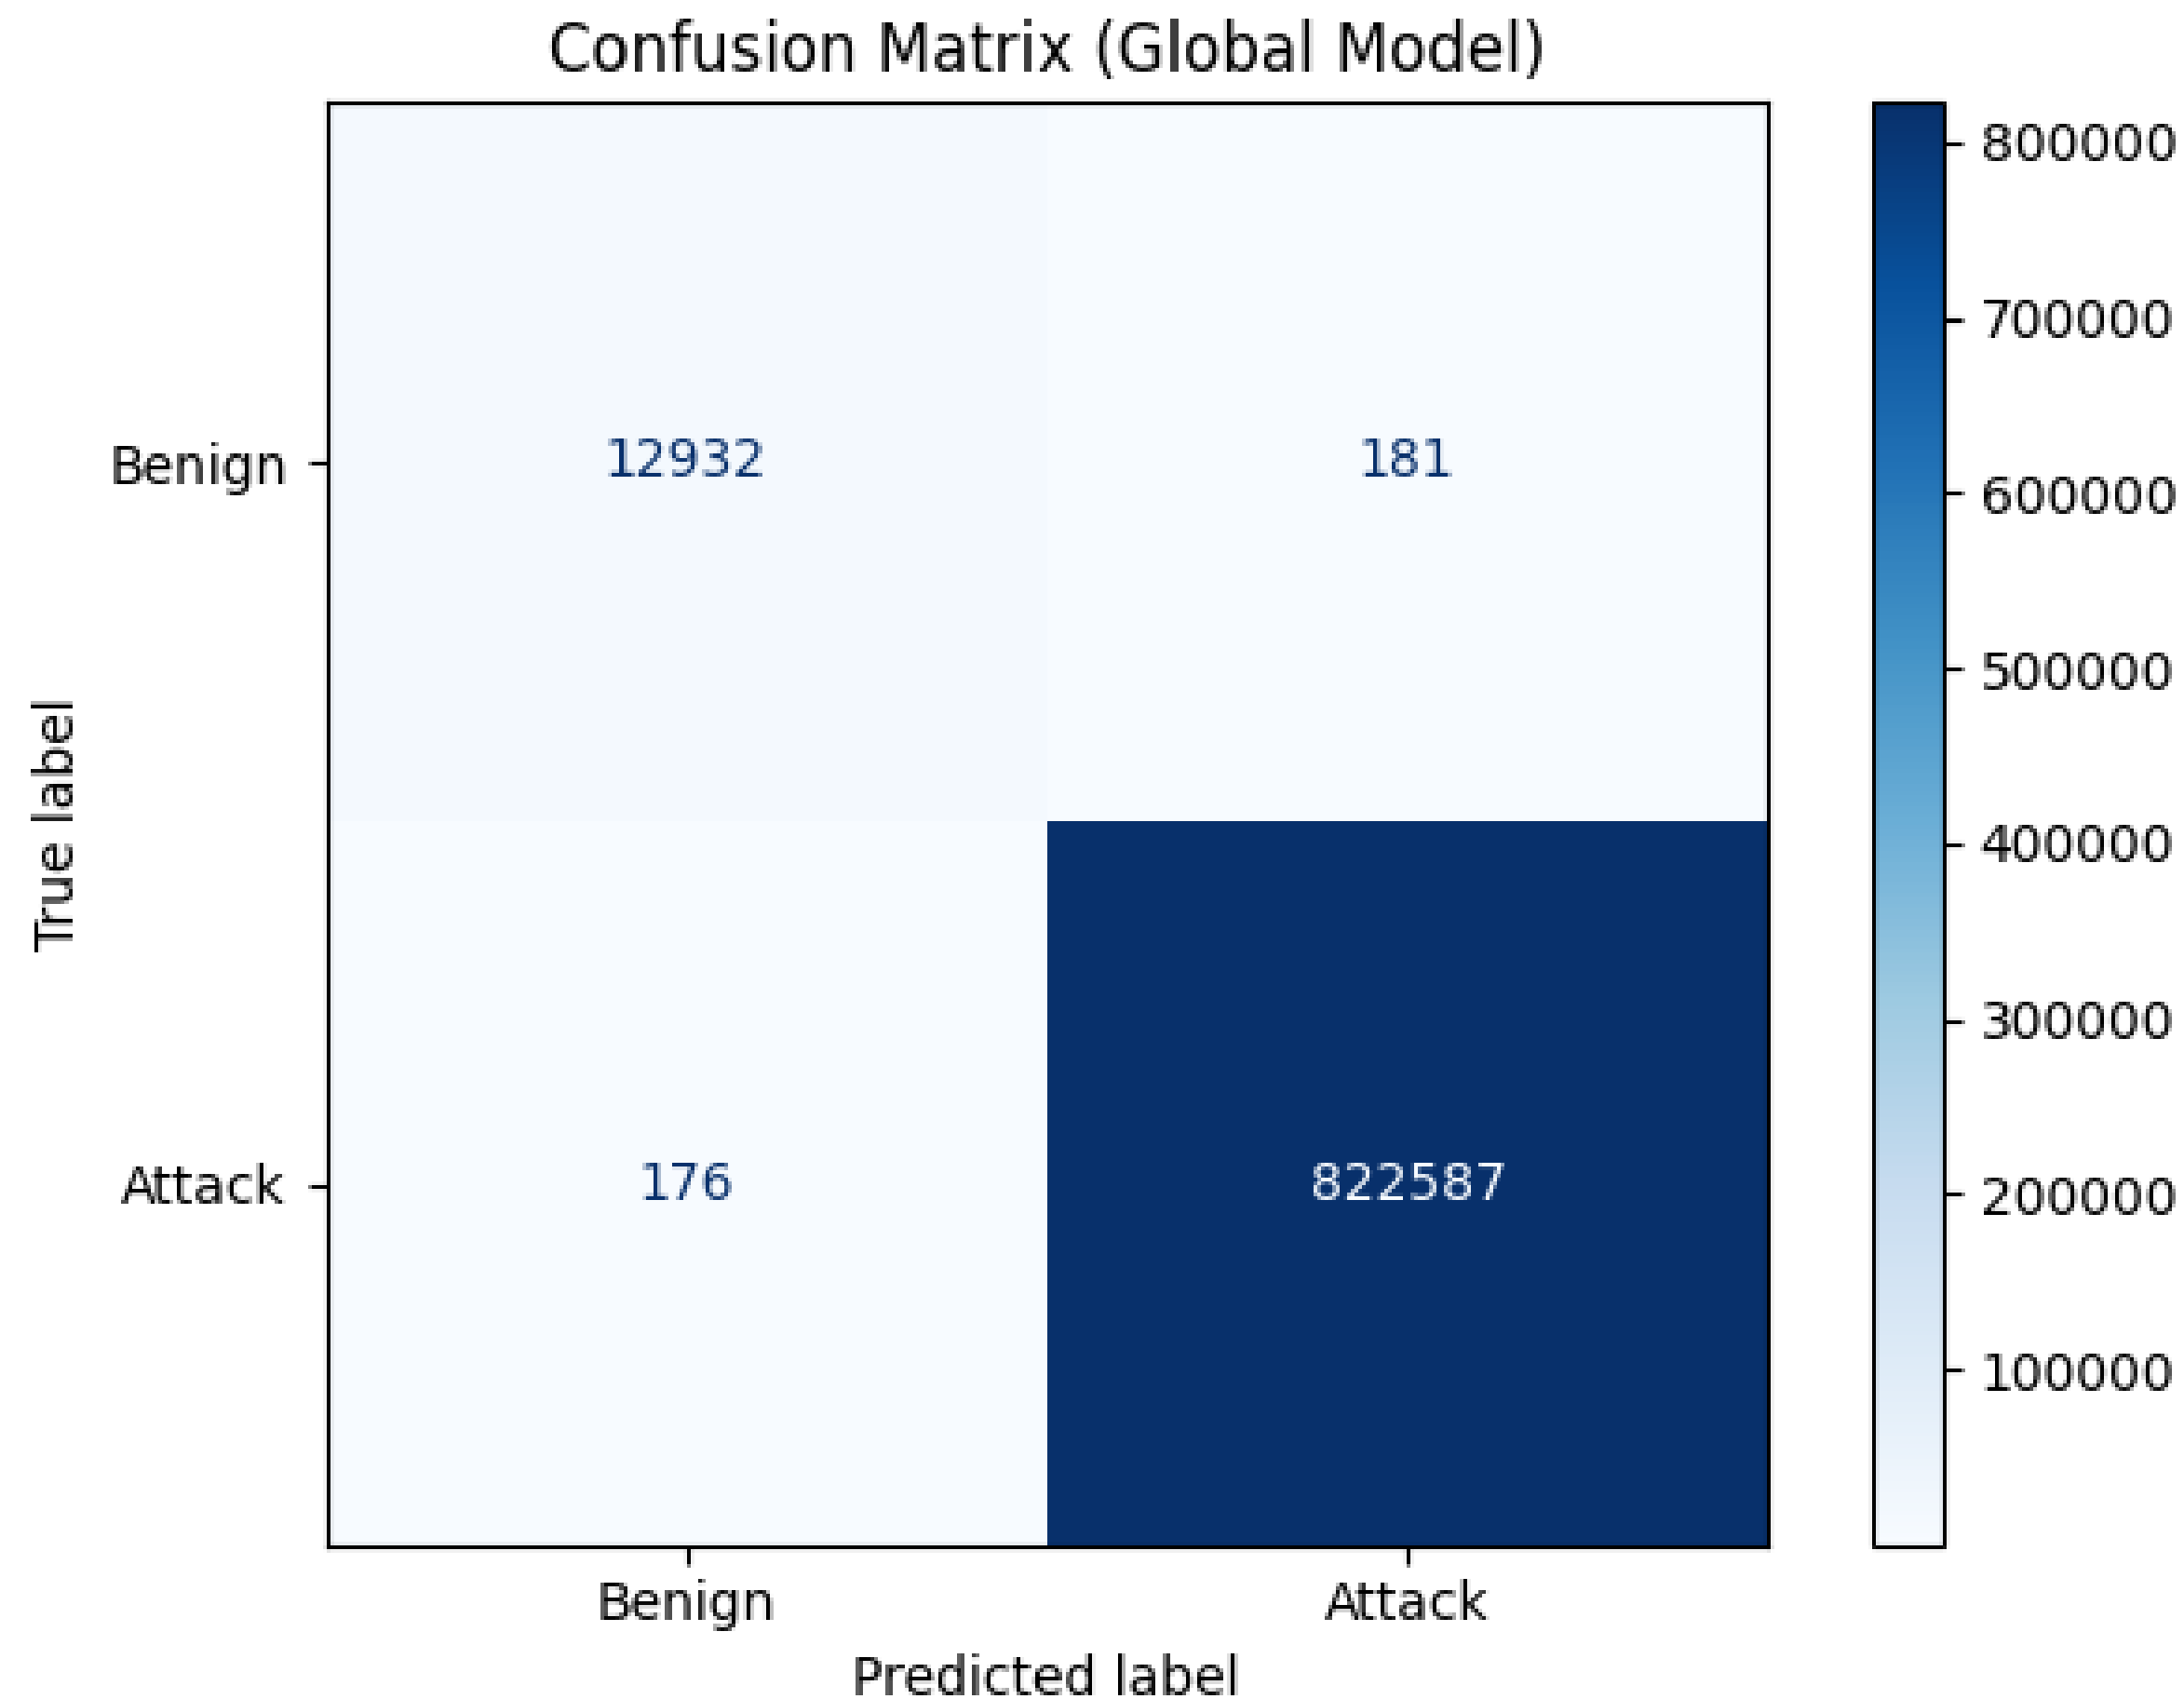
실제 재현 결과(2): Confusion Matrix

Confusion Matrix

- 행렬의 각 면은 정상 데이터를 정상 판단 및 오탐, 공격 데이터의 오탐 및 공격 판단으로 나뉘어짐
- 일반적으로, 네트워크 침입은 공격 트래픽이 많기 때문에, 정상데이터 보다 공격 데이터의 수가 많음

평가 지표

- 오차 행렬의 평가 지표로 Accuracy, Recall, Precision, F1-score를 선택
- 지표는 각각 0.99, 0.98, 0.98, 0.98로 실험 값과 유사한 수치 달성



결론 및 향후 연구

논문의 기여점 결론

01. 알고리즘 기여 (FedDetect)

- 적용형 옵티마이저: FedAvg 대신 Adam 기반 집계로 성능 향상
- 라운드 간 LR 스케줄러: 라운드별 학습률 동적 조정으로 안정적 수렴
- Global Threshold: 디바이스별 MSE 시퀀스로 통합 임계값 산출

02. 시스템 기여 (FedIoT)

- 실제 하드웨어 테스트베드: Raspberry Pi 기반 온디바이스 검증
- 3계층 아키텍처: 애플리케이션/알고리즘/인프라 계층 분리로 확장성 제공
- Python 통합 개발: 단일 언어로 시스템 프로토타입 용이성

03. 방법론 & 실증 결과

- 테스트셋 합성 규칙: 재현 가능한 공정한 평가 시나리오 제안
- 다양한 공격 탐지: 여러 장치 협력으로 광범위한 공격 유형 탐지 가능
- 성능 근접도: 중앙학습(상한) 수준에 근접한 FL 성능 입증
- 자원 제약 실용성: 메모리/시간 효율적, 실제 IoT 환경 가능성 확인

한계점 및 향후 연구

현재 한계점

- **Non-IID 강도 증가:** 데이터 편차가 클수록 FPR 상승, 성능 저하 가능성
- **데이터 편향:** 단일 장치가 모든 공격 유형을 관찰하지 못함
- **모델 다양성:** Autoencoder 외 고급 모델 적용 시 추가 엔지니어링 비용
- **임계값 설정:** 장치별 특성 차이로 통합 임계값의 효과 제한적일 수 있음

향후 연구 방향

- **개인화 및 도메인 적응:** 장치별 특성 보존하며 지식 공유 (FedBN, FedPer)
- **비동기/선택적 FL:** 모든 장치 동기화 없이 효율적 학습 방식 연구
- **임계값 학습 자동화:** 장치별 최적 임계값 동적 조정 메커니즘 개발
- **대규모 실제 배치 평가:** 다양한 실제 IoT 네트워크에서 검증 필요

감사합니다
